

APPSPEC: Sistema de Apoio ao Diagnóstico de Apendicite Combinando Escore de Alvarado, K-Nearest Neighbors e Support Vector Machine — Abordagem Pedagógica para Sistemas Clínicos Inteligentes

Francisco Neri · Anahi Philbois · Murilo Borges Ribeiro
Instituto de Informática · Universidade Federal de Goiás (UFG)
Trabalho de Conclusão · Disciplina de Frameworks · Prof. Ronaldo Martins da Costa · 2026

RESUMO

CONTEXTO:

OBJETIVO:

METODOS:

RESULTADOS:

CONCLUSAO:

Apendicite aguda e a emergencia cirurgica abdominal mais frequente.

Desenvolver o APPSPEC, CDSS combinando Escore de Alvarado e KNN.

Dataset Regensburg (N=782, UCI id=938), 32 features, KNeighborsClassifier (k=5).

KNN: acuracia 75.2%, sensibilidade 81.8%. SVM: acuracia 80.5%. Alvarado: sensibilidade 83.3%.

Viabilidade demonstrada para apoio diagnostico com tecnologias da disciplina.

Palavras-chave: Sistemas Clínicos Inteligentes · K-Nearest Neighbors · Support Vector Machine · Escore de Alvarado · Django · Apoio ao Diagnóstico · Apendicite

1. INTRODUÇÃO

Apendicite aguda é a principal causa de abdome agudo cirúrgico em crianças e adultos jovens, com incidência de 7–8% ao longo da vida [1]. O diagnóstico tardio eleva o risco de perfuração para mais de 80% em menores de cinco anos, podendo evoluir para peritonite e sepse [2].

O Escore de Alvarado (1986) [1] sistematiza oito critérios clínico-laboratoriais em 0–10 pontos: migração da dor para a fossa ilíaca direita (FID), anorexia, náuseas/vômitos, dor à palpação em FID (peso 2), sinal de Blumberg, temperatura >37,3°C, leucocitose >10.000/mm³ (peso 2) e neutrofilia. Escores ≤4 permitem alta com sensibilidade 99% (corte 5); ≥7 indicam cirurgia imediata (especificidade 81%, corte 7) [5]. A meta-análise de Ohle et al. [5] confirmou esses pontos de corte em 42 estudos independentes.

O K-Nearest Neighbors (KNN) [6] classifica casos pela votação dos k vizinhos mais próximos no espaço euclidiano de features — geometricamente interpretável e adequado a datasets de médio porte. O Support Vector Machine (SVM) [7] encontra o hiperplano de máxima margem entre as classes, com robustez reconhecida em dados clínicos tabulares. Estudos recentes aplicaram ambos em diagnóstico de apendicite com acurácia de 64–84% em dados clínicos [8, 9].

O APPSPEC integra os três métodos — Escore de Alvarado, KNN e SVM — em plataforma web com duplo objetivo: prover estimativa de risco de apendicite e demonstrar pedagogicamente Django, scikit-learn, pandas, joblib e Orange3.

2. MATERIAIS E MÉTODOS

- 2.1 Dataset
- Regensburg Pediatric Appendicitis [3], N=782, 753 validos apos exclusao.
- 2.2 Preparacao dos dados
- 32 features tabulares. 2543 valores imputados por mediana.
- 2.3 KNN
- k=5, distancia euclidiana, candidatos testados: [3, 5, 7, 9, 11] [6].
- 2.4 SVM
- Kernel linear, C=10.0 [10].
- 2.5 Avaliacao
- Conjunto de teste retido: n=113 (15% de 753).

3. RESULTADOS

A

Tabela 1. Comparação de desempenho no conjunto de teste (N=113). *Config F: LIMPO, k=5, n=527. †Data leakage confirmado.

Modelo / Config	Acurácia	Sensib.	Especif.	VPP	VPN
Alvarado Score (corte ≥5)	68,1%	83,3%	46,8%	68,8%	66,7%
KNN Config E (7 individuais + Free, k=11)	69,5%	—	—	—	—
KNN Config F* (k=5)	75,2%	81,8%	66,0%	77,1%	72,1%
SVM (linear, C=10.0)	80,5%	80,3%	80,9%	85,5%	74,5%
Config D (descartada)†	95,6%	—	—	—	—

compara o desempenho dos modelos.

KNN: VP=54 FP=16 FN=12 VN=31 (acuracia 75.2%). SVM: VP=53 FP=9 FN=13 VN=38 (acuracia 80.5%). Alvarado: VP=55 FP=25 FN=11 VN=22 (acuracia 68.1%).




Figura 1. Matriz de Confusão do KNN no conjunto de teste (N=113).
Diagonal (acertos): 31 pacientes sem apendicite + 54 com apendicite = 85 corretos (75,2%). Erros: 16 falsos positivos e 12 falsos negativos.




Figura 2. Matriz de Confusão do SVM (kernel=linear, C=10.0, N=113).
VP=53, FP=9, FN=13, VN=38. Acurácia 80,5%, sensibilidade 80,3%, especificidade 80,9%.




Figura 4. Curvas ROC (Receiver Operating Characteristic) comparativas entre KNN, SVM e Regra Clínica de Alvarado.




Figura 5. Curvas Precision-Recall comparativas entre KNN, SVM e Regra Clínica de Alvarado.

4. DISCUSSÃO

O APPSPEC atingiu acuracia de 75.2% com KNN e 80.5% com SVM, valores alinhados com a literatura para dados tabulares clinicos [3, 8].

O Alvarado apresentou sensibilidade superior (83.3%) mas especificidade baixa (46.8%). SVM obteve o melhor equilibrio.

As curvas ROC e Precision-Recall demonstram graficamente a estabilidade e superioridade do SVM de kernel linear comparado aos outros métodos na área sob a curva (AUC).

O APPSPEC cumpriu seu proposito pedagogico de tornar visiveis as tecnologias ensinadas na disciplina.

Limitacoes: dataset pediatrico alemao (2016-2021), generalizacao incerta para outras populacoes.

5. CONCLUSÃO

O APPSPEC demonstrou viabilidade do KNN e SVM tabulares para apoio ao diagnostico, com acuracia 75.2% e 80.5% respectivamente.

Proximos passos: (a) endpoint REST com HL7 FHIR R4; (b) plataforma de modelos clinicos via API [9]; (c) explicabilidade via SHAP.

Declaracao de uso de IA generativa: Os autores utilizaram ferramentas de IA generativa (Antigravity e Claude AI) como apoio na redacao e desenvolvimento. Todo o conteudo foi revisado e validado pelos autores.




Figura 3. Interface do APPSPEC exibindo resultado simultâneo para um paciente com todos os critérios de Alvarado positivos (escore 10/10). Da esquerda para direita: Escore de Alvarado (regra clínica determinística), KNN (80,0% de probabilidade, k=5 vizinhos) e SVM (91,8% de probabilidade, kernel linear). A interface pedagógica exibe o algoritmo de cálculo de cada método, as referências DOI e o disclaimer clínico obrigatório.

REFERÊNCIAS

[1] Alvarado A. A practical score for the early diagnosis of acute appendicitis. Ann Emerg Med. 1986;15:557–64. DOI:10.1016/S0196-0644(86)80468-2

[2] Bai S et al. Alvarado Score for Appendicitis in Children: Systematic Review and Meta-Analysis. J Pediatr Surg. 2023.

[3] Marcinkevics R et al. Regensburg Pediatric Appendicitis [Dataset]. UCI ML Repository; 2023. DOI:10.5281/zenodo.7669442

[4] Pedregosa F et al. Scikit-learn: Machine Learning in Python. JMLR. 2011;12:2825–30.

[5] Ohle R et al. The Alvarado score for predicting acute appendicitis: a systematic review. BMC Med. 2011;9:139. DOI:10.1186/1741-7015-9-139

[6] Cover T, Hart P. Nearest neighbor pattern classification. IEEE Trans Inf Theory. 1967;13:21–7. DOI:10.1109/TIT.1967.1053964

[7] Cortes C, Vapnik V. Support-vector networks. Machine Learning. 1995;20(3):273–297. DOI:10.1007/BF00994018

[8] Gollapalli M et al. Appendicitis Diagnosis: Ensemble ML and XAI. Big Data Cogn Comput. 2024.

[9] Uddin S et al. Comparative performance of KNN variants for disease prediction. Sci Rep. 2022.

[10] Kaufman S et al. Leakage in Data Mining. KDD. 2012. DOI:10.1145/2020408.2020496

[11] Panitz LM, Prata DN, Rodrigues W. Análise do desempenho dos hospitais públicos e privados que atendem ao SUS. Cad Saúde Pública. 2024;40(9):e00156023. DOI:10.1590/0102-311XPT156023