

APPSPEC: Sistema de Apoio ao Diagnóstico de Apendicite Combinando Escore de Alvarado, K-Nearest Neighbors e Support Vector Machine — Abordagem Pedagógica para Sistemas Clínicos Inteligentes

Francisco Neri · Anahi Philbois · Murilo Borges Ribeiro

Instituto de Informática · Universidade Federal de Goiás (UFG)

Trabalho de Conclusão · Disciplina de Frameworks · Prof. Ronaldo Martins da Costa · 2026

RESUMO

CONTEXTO:

A apendicite aguda é a emergência cirúrgica abdominal mais frequente na pediatria.

OBJETIVO:

O presente estudo tem como objetivo desenvolver o APPSPEC, um Sistema de Apoio à Decisão Clínica (CDSS) combinando a regra tradicional do Escore de Alvarado com modelos de K-Nearest Neighbors (KNN).

MÉTODOS:

Utilizou-se o dataset Regensburg Pediatric Appendicitis (N=782, UCI id=938). Após o pré-processamento, mantiveram-se 753 pacientes e 32 features normalizadas (MinMaxScaler). Os dados foram particionados com random_state fixo. Avaliou-se o algoritmo KNN (k=11) e SVM.

RESULTADOS:

No conjunto de teste, o KNN obteve acurácia de 74.3% e sensibilidade de 78.8%. O SVM alcançou acurácia de 82.3%. Em contraste, o Alvarado teve a maior sensibilidade (83.3%), porém baixa especificidade.

CONCLUSÃO:

O APPSPEC demonstra a viabilidade do uso de aprendizado de máquina tabular como ferramenta pedagógica e de triagem complementar, salientando o balanço crítico entre falsos positivos e negativos na prática cirúrgica.

Palavras-chave: Sistemas Clínicos Inteligentes · K-Nearest Neighbors · Support Vector Machine · Escore de Alvarado · Django · Apoio ao Diagnóstico · Apendicite

1. INTRODUÇÃO

Apendicite aguda é a principal causa de abdome agudo cirúrgico em crianças e adultos jovens, com incidência de 7–8% ao longo da vida [1]. O diagnóstico tardio eleva o risco de perfuração para mais de 80% em menores de cinco anos, podendo evoluir para peritonite e sepse [2].

O Escore de Alvarado (1986) [1] sistematiza oito critérios clínico-laboratoriais em 0–10 pontos: migração da dor para a fossa ilíaca direita (FID), anorexia, náuseas/vômitos, dor à palpação em FID (peso 2), sinal de Blumberg, temperatura $>37,3^{\circ}\text{C}$, leucocitose $>10.000/\text{mm}^3$ (peso 2) e neutrofilia. Escores ≤ 4 permitem alta com sensibilidade 99% (corte 5); ≥ 7 indicam cirurgia imediata (especificidade 81%, corte 7) [5]. A meta-análise de Ohle et al. [5] confirmou esses pontos de corte em 42 estudos independentes.

O K-Nearest Neighbors (KNN) [6] classifica casos pela votação dos k vizinhos mais próximos no espaço euclidiano de features — geometricamente interpretável e adequado a datasets de médio porte. O Support Vector Machine (SVM) [7] encontra o hiperplano de máxima margem entre as classes, com robustez reconhecida em dados clínicos tabulares. Estudos recentes aplicaram ambos em diagnóstico de apendicite com acurácia de 64–84% em dados clínicos [8, 9].

O APPSPEC integra os três métodos — Escore de Alvarado, KNN e SVM — em plataforma web com duplo objetivo: prover estimativa de risco de apendicite e demonstrar pedagogicamente Django, scikit-learn, pandas, joblib e Orange3.

2. MATERIAIS E MÉTODOS

2.1 Origem dos Dados

Utilizou-se o dataset pediátrico de Regensburg [3] com 782 pacientes. Foram excluídas variáveis associadas a data leakage (ex: pontuações Alvarado já calculadas previamente, que vazam o desfecho diagnóstico).

2.2 Pré-processamento e Imputação

Restaram N=753 pacientes. Foi realizada imputação pela mediana (2543 valores) e normalização Min-Max. A imputação e o escalonamento foram ajustados exclusivamente no conjunto de treino e aplicados ao teste, garantindo rigor e ausência de vazamento de dados estatísticos.

2.3 Modelos Preditivos

O KNN [6] utilizou KNeighborsClassifier [4]. A seleção do hiperparâmetro k ótimo (k=11) foi feita via validação cruzada 5-fold no conjunto de treino. O SVM utilizou Kernel linear e hiperparâmetro C=10.0, estabelecido através de busca em grade (grid search) com validação cruzada [7].

2.4 Arquitetura do Sistema Integrado

O modelo foi integrado ao Framework Django (padrão MVT) e banco SQLite. A persistência dos modelos scikit-learn foi realizada via `joblib`. Os dados do formulário web são traduzidos nativamente para arrays NumPy, normalizados, e processados em tempo real pelas camadas de Machine Learning, exibindo os resultados em uma interface responsiva voltada ao ensino e discussão clínica.

2.5 Avaliação

O desempenho final comparativo foi mensurado via holdout estratificado estrito no conjunto de teste (n=113).

3. RESULTADOS

A

Tabela 1. Comparação de desempenho no conjunto de teste (N=113, prevalência de apendicite ~66/113). †Data leakage confirmado. Nota: A Config E foi testada preliminarmente (acurácia 69,5%, k=11), sendo inferior à Config F.

Modelo / Config	Acurácia	Sensib.	Especif.	VPP	VPN
Alvarado Score (corte ≥5)	68,1%	83,3%	46,8%	68,8%	66,7%
KNN Config F (Tabular, k=11)	74,3%	78,8%	68,1%	77,6%	69,6%
SVM (linear, C=10.0)	82,3%	83,3%	80,9%	85,9%	77,6%
Config D (descartada)†	95,6%	—	—	—	—

compara o desempenho dos modelos.

KNN: VP=52 FP=15 FN=14 VN=32 (acuracia 74.3%). SVM: VP=55 FP=9 FN=11 VN=38 (acuracia 82.3%). Alvarado: VP=55 FP=25 FN=11 VN=22 (acuracia 68.1%).




Figura 1. Matriz de Confusão do KNN no conjunto de teste (N=113). Diagonal (acertos): 32 pacientes sem apendicite + 52 com apendicite = 84 corretos (74,3%). Erros: 15 falsos positivos e 14 falsos negativos.




Figura 2. Matriz de Confusão do SVM (kernel=linear, C=10.0, N=113). VP=55, FP=9, FN=11, VN=38. Acurácia 82,3%, sensibilidade 83,3%, especificidade 80,9%.




Figura 4. Curvas ROC (Receiver Operating Characteristic) comparativas entre KNN, SVM e Regra Clínica de Alvarado.




Figura 5. Curvas Precision-Recall comparativas entre KNN, SVM e Regra Clínica de Alvarado.




Figura 3. Interface do APPSPEC exibindo resultado simultâneo para um paciente com todos os critérios de Alvarado positivos (escore 10/10). Da esquerda para direita: Escore de Alvarado (regra clínica determinística), KNN (probabilidade calculada, k=11 vizinhos) e SVM (probabilidade alta, kernel linear).

Nota: Os percentuais em destaque nos painéis referem-se à probabilidade de apendicite para este caso específico, não devendo ser confundidos com a acurácia global do modelo reportada na Tabela 1.

4. DISCUSSÃO

O APPSPEC atingiu acurácia de 74.3% com KNN e 82.3% com SVM. Com um N=113 de teste, a prevalência de apendicite neste conjunto foi de aproximadamente 58% (~58%), o que eleva artificialmente o VPP se comparado a uma emergência padrão. A margem de erro estimada é de cerca de 7,4 pp.

No trade-off clínico, falsos negativos acarretam morbidade severa (peritonite). O Escore de Alvarado obteve a maior sensibilidade (83.3%) com corte ≥ 5 . Contudo, a comparação binária subestima a verdadeira utilidade clínica do Alvarado, que foi projetado com múltiplos limiares (≤ 4 = alta segura, ≥ 7 = cirurgia) [2]. O SVM obteve o melhor equilíbrio global de triagem tabular.

As curvas ROC e Precision-Recall demonstram graficamente a estabilidade e superioridade do SVM de kernel linear na área sob a curva (AUC).

O disclaimer obrigatório do sistema enfatiza que as ferramentas de IA não substituem o julgamento clínico presencial.

Limitações: o uso do dataset pediátrico alemão de Regensburg [3] compromete a generalização, pois o perfil epidemiológico, laboratorial e a disponibilidade de exames pediátricos no SUS [11] diferem substancialmente. Estudos de validação externa locais são imperativos para sistemas de inteligência artificial clínica [12].

5. CONCLUSÃO

O APPSPEC demonstrou a viabilidade do KNN e SVM tabulares para apoio ao diagnóstico, com acurácia de 74.3% e 82.3%, respectivamente.

Próximos passos: (a) endpoint REST com HL7 FHIR R4; (b) validação clínica externa no Brasil [11, 12]; (c) explicabilidade via SHAP e análise rigorosa de Missing Data.

Declaração de uso de Inteligência Artificial: Os autores utilizaram ferramentas de IA generativa (Antigravity e Claude AI) como apoio na redação e desenvolvimento. Todo o conteúdo foi revisado e validado pelos autores, que assumem total responsabilidade pelo trabalho.

REFERÊNCIAS

[1] Alvarado A. A practical score for the early diagnosis of acute appendicitis. Ann Emerg Med. 1986;15:557–64. DOI:10.1016/S0196-0644(86)80468-2

[2] Bai S et al. Alvarado Score for Appendicitis in Children: Systematic Review and Meta-Analysis. J Pediatr Surg. 2023.

[3] Marcinkevics R et al. Regensburg Pediatric Appendicitis [Dataset]. UCI ML Repository; 2023. DOI:10.5281/zenodo.7669442

[4] Pedregosa F et al. Scikit-learn: Machine Learning in Python. JMLR. 2011;12:2825–30.

[5] Ohle R et al. The Alvarado score for predicting acute appendicitis: a systematic review. BMC Med. 2011;9:139. DOI:10.1186/1741-7015-9-139

[6] Cover T, Hart P. Nearest neighbor pattern classification. IEEE Trans Inf Theory. 1967;13:21–7. DOI:10.1109/TIT.1967.1053964

[7] Cortes C, Vapnik V. Support-vector networks. Machine Learning. 1995;20(3):273–297. DOI:10.1007/BF00994018

[8] Gollapalli M et al. Appendicitis Diagnosis: Ensemble ML and XAI. Big Data Cogn Comput. 2024.

[9] Uddin S et al. Comparative performance of KNN variants for disease prediction. Sci Rep. 2022.

[10] Kaufman S et al. Leakage in Data Mining. KDD. 2012. DOI:10.1145/2020408.2020496

[11] Panitz LM, Prata DN, Rodrigues W. Análise do desempenho dos hospitais públicos e privados que atendem ao SUS. Cad Saúde Pública. 2024;40(9):e00156023. DOI:10.1590/0102-311XPT156023

[12] Futoma J, Simons M, Panch T, et al. The myth of generalisability in clinical AI: a route to robust medicine. Lancet Digit Health. 2020;2(9):e489-e492. DOI:10.1016/S2589-7500(20)30186-4